



Universidade Federal do Ceará
Centro de Ciências
Departamento de Computação
Tópicos Avançados em Aprendizado de Máquina (CK0255)

Proposta de Projeto Final: Aprendizado Profundo

Gabriel Batista Monteiro - 542561

Sumário

1. Artigo Principal Escolhido	2
2. Resumo da Principal Contribuição	2
3. Plano para Implementação	3
3.1 Contribuição Chave a Implementar	3
3.2 Dataset e Arquitetura	3
4. Revisão Bibliográfica e Contextualização	4
5. Referências	5

1. Artigo Principal Escolhido

Título: On Large-Batch Training for Deep Learning: Generalization Gap and Sharp Minima. **Autores:** Nitish Shirish Keskar, Dheevatsa Mudigere, Jorge Nocedal, Mikhail Smelyanskiy, Ping Tak Peter Tang (ICLR, 2017).

2. Resumo da Principal Contribuição

O artigo de Keskar et al. aborda um problema fundamental na otimização estocástica para Deep Learning: o **generalization gap** (lacuna de generalização) observado quando se treina modelos com grandes tamanhos de batch. Embora o uso de grandes batches seja desejável para paralelização massiva e aceleração do treinamento em hardware moderno (GPUs/TPUs), os autores demonstram empiricamente que isso resulta em modelos com performance de teste significativamente inferiores aos treinados com pequenos batches, mesmo quando a acurácia de treino é idêntica.

A contribuição central do trabalho é a **caracterização geométrica** desse fenômeno. Os autores propõem e evidenciam que:

1. **Mínimos Planos vs. Agudos:** O treinamento com Small-Batch (SB) tende a convergir para "Mínimos Planos" (Flat Minima), que são regiões da função de custo onde a precisão é robusta a pequenas perturbações nos parâmetros. Em contraste, o treinamento com Large-Batch (LB) tende a ser atraído para "Mínimos Agudos" (Sharp Minima), onde a curvatura da função de custo é alta.
2. **Causa do Fenômeno:** O ruído intrínseco na estimativa dos gradientes computados em batches pequenos atua como uma regularização, permitindo que o otimizador escape das bacias de atração de mínimos agudos e instáveis. Em batches grandes, esse ruído é suprimido, fazendo com que o modelo convirja prematuramente para o mínimo agudo mais próximo da inicialização.
3. **Impacto na Generalização:** Como as funções de treino e teste não são idênticas (devido à amostragem dos dados), um mínimo agudo na função de treino provavelmente não corresponderá a um mínimo na função de teste, levando a uma alta taxa de erro. Mínimos planos, por serem regiões vastas de baixo erro, mantêm a performance mesmo com o deslocamento natural entre as superfícies de erro de treino e teste.

3. Plano para Implementação

O objetivo é criar uma prova de conceito funcional que valide a hipótese dos "Mínimos Planos vs. Agudos" através da reprodução dos experimentos-chave do artigo.

3.1 Contribuição Chave a Implementar

Será implementado um pipeline de treinamento comparativo para investigar a topologia da perda. A implementação consistirá em três etapas principais:

- 1. Treinamento Dual:** Treinar duas instâncias de uma mesma Rede Neural Convolucional (CNN).
 - **Modelo SB:** Treinado com batch size pequeno.
 - **Modelo LB:** ajustando a learning rate seguindo diretrizes como a "**Linear Scaling Rule**" ($LR \propto \text{BatchSize}$) e/ou **Warmup**, essenciais para garantir a estabilidade e uma comparação justa conforme Keskar et al.
- 2. Métrica de Sensibilidade (Sharpness):** Será implementado a métrica proposta no artigo para quantificar a "agudeza" do mínimo encontrado, medindo a degradação da acurácia quando adicionamos ruído aos pesos da rede treinada.
- 3. Visualização Paramétrica 1D (Figura 2 do Artigo):** Será implementado a visualização da barreira de energia entre as soluções. Isso envolve interpolar os pesos entre a solução do batch pequeno (x_s^*) e a solução do batch grande (x_l^*) e plotar o valor da Loss e da Acurácia ao longo dessa linha. Espera-se ver que x_s^* reside em um "vale" largo, enquanto x_l^* está em um buraco estreito.

3.2 Dataset e Arquitetura

- 1. Dataset:** Será utilizado o **CIFAR-10**. Este dataset foi escolhido em vez do MNIST porque a complexidade das imagens naturais do CIFAR-10 é necessária para que o fenômeno do *generalization gap* se manifeste claramente. O MNIST é frequentemente fácil demais, permitindo convergência para mínimos globais triviais independente do batch.
- 2. Arquitetura:** Será utilizado uma arquitetura estilo **VGG simplificada** (inspirada em Simonyan & Zisserman, 2014), adequada para o CIFAR-10, contendo blocos convolucionais com **Batch Normalization**, seguidos de *Max Pooling* e camadas *Fully Connected* com Dropout.

4. Revisão Bibliográfica e Contextualização

Para fundamentar a implementação e análise, foram selecionados três artigos complementares que formam a base teórica sobre arquiteturas, regularização e otimização, criando uma narrativa coesa sobre a generalização em Deep Learning.

1. **Arquitetura: *Very Deep Convolutional Networks for Large-Scale Image Recognition* (Simonyan & Zisserman, 2014).** Este trabalho (VGG) estabeleceu o paradigma de que a profundidade é crucial para a extração de representações hierárquicas complexas. No entanto, o aumento da profundidade torna a superfície de erro não-convexa extremamente complexa, repleta de mínimos locais e pontos de sela. O projeto que será trabalhado utiliza uma arquitetura baseada nos princípios da VGG para garantir que o modelo tenha capacidade suficiente para sofrer dos problemas de otimização descritos por Keskar et al.
2. **Regularização: *Dropout: A Simple Way to Prevent Neural Networks from Overfitting* (Srivastava et al., 2014).** Srivastava e outros introduziram o Dropout como uma técnica explícita para quebrar co-adaptações complexas entre neurônios, forçando a rede a aprender características robustas. Keskar e outros dialogam diretamente com este trabalho ao argumentar que o gradiente estocástico de *small-batch* atua como uma forma de regularização implícita, similar em espírito ao Dropout. No experimento que será trabalhado, será analisado se o efeito geométrico do tamanho do batch persiste mesmo na presença do Dropout clássico.
3. **Otimização: *Adam: A Method for Stochastic Optimization* (Kingma & Ba, 2014).** Enquanto Keskar foca na geometria, Kingma & Ba focam na eficiência do algoritmo de descida, propondo o Adam, que adapta as taxas de aprendizado baseando-se nos momentos dos gradientes. O artigo de Keskar discute que, embora métodos adaptativos como o Adam ajudem na convergência, eles não imunizam o modelo contra a atração por mínimos agudos em regimes de *Large-Batch*. Este artigo foi incluído para contrastar a performance do SGD puro versus Adam na implementação que será feita, verificando se o *generalization gap* é mitigado ou exacerbado pelo otimizador escolhido.

Conclusão: A união desses trabalhos sugere que a generalização não depende apenas da arquitetura (VGG) ou de regularizadores explícitos (Dropout), mas da dinâmica de otimização (Adam vs SGD) e dos hiperparâmetros de treinamento (tamanho do Batch), que ditam a geometria final da solução encontrada.

5. Referências Bibliográficas

- [1] Keskar, N. S., Mudigere, D., Nocedal, J., Smelyanskiy, M., & Tang, P. T. P. (2017).** On Large-Batch Training for Deep Learning: Generalization Gap and Sharp Minima. In International Conference on Learning Representations (ICLR).
- [2] Kingma, D. P., & Ba, J. (2015).** Adam: A Method for Stochastic Optimization. In International Conference on Learning Representations (ICLR).
- [3] Simonyan, K., & Zisserman, A. (2015).** Very Deep Convolutional Networks for Large-Scale Image Recognition. In International Conference on Learning Representations (ICLR).
- [4] Srivastava, N., Hinton, G., Krizhevsky, A., Sutskever, I., & Salakhutdinov, R. (2014).** Dropout: A Simple Way to Prevent Neural Networks from Overfitting. Journal of Machine Learning Research, 15(1), 1929-1958.