



Universidade Federal do Ceará
Centro de Ciências
Departamento de Computação
Tópicos Avançados em Aprendizado de Máquina (CK0255)

Relatório Final:

Projeto de Aprendizado Profundo

Gabriel Batista Monteiro - 542561
Luan Icaro Ferreira Santos - 415170

Sumário

1. Introdução	2
2. Referencial Teórico	3
2.2 Arquiteturas Convolucionais Profundas (VGG)	4
2.3 Regularização e Dinâmica de Treinamento	4
3. Metodologia	5
3.1 Reprodução Experimental	5
3.2 Extensão para Detecção de Objetos (YOLO)	6
4. Experimentos e Resultados	7
4.1 Resultados da Classificação	7
4.2 Validação em Detecção de Objetos	10
5. Discussão e Análise Crítica	11
6. Conclusão e Trabalhos Futuros	12

1. Introdução

O treinamento de Redes Neurais Profundas (Deep Learning) em larga escala impõe desafios computacionais significativos, impulsionando o desenvolvimento de hardwares especializados com alto grau de paralelismo, como GPUs e TPUs. Para explorar eficientemente esse paralelismo, é comum a utilização de métodos de otimização estocástica com grandes tamanhos de lote (*Large-Batch Training*). Entretanto, a literatura aponta para uma deficiência crítica nessa abordagem: modelos treinados com grandes lotes tendem a apresentar uma capacidade de generalização inferior àqueles treinados com pequenos lotes (*Small-Batch*), um fenômeno conhecido como *Generalization Gap*.

Este trabalho investiga a hipótese geométrica proposta por Keskar et al. (2017), que sugere que o tamanho do lote influencia diretamente a topologia dos mínimos locais encontrados durante a otimização. A hipótese postula que o treinamento com pequenos lotes, devido ao ruído intrínseco na estimativa do gradiente, tende a convergir para "Mínimos Planos" (*Flat Minima*) — regiões vastas de baixo erro que são robustas a perturbações nos parâmetros e, conseqüentemente, generalizam melhor. Em contraste, o treinamento com grandes lotes tende a ser atraído para "Mínimos Agudos" (*Sharp Minima*), onde a função de custo cresce abruptamente nas vizinhanças da solução, resultando em maior sensibilidade e pior generalização.

O objetivo deste projeto é reproduzir e validar empiricamente essas observações. Para isso, implementamos um estudo comparativo utilizando a arquitetura VGG no dataset CIFAR-10, analisando não apenas a acurácia, mas também a geometria da função de perda através de visualizações paramétricas e testes de sensibilidade a ruído. Adicionalmente, expandimos o escopo do estudo original aplicando a hipótese em um cenário de detecção de objetos utilizando a rede YOLO, a fim de verificar se a fragilidade dos mínimos agudos persiste em tarefas de visão computacional mais complexas e datasets do mundo real.

2. Referencial Teórico

A capacidade de generalização de modelos de Aprendizado Profundo (*Deep Learning*) não é determinada apenas pela quantidade de dados ou pela profundidade da rede, mas é intrinsecamente moldada pela dinâmica do algoritmo de otimização e pela geometria da superfície de erro (perda) onde a solução final reside. Nesta seção, discutimos os fundamentos teóricos que sustentam a hipótese dos "Mínimos Planos", bem como as escolhas de arquiteturas e de regularização adotadas neste estudo.

2.1 Otimização Estocástica e a Geometria dos Mínimos Locais

O treinamento de redes neurais profundas envolve a minimização de uma função de custo não-convexa de alta dimensão. O método predominante para essa tarefa é o Gradiente Descendente Estocástico (SGD) e suas variantes. A escolha do tamanho do lote (*batch size*) no SGD não afeta apenas a eficiência computacional, mas altera a própria trajetória de otimização.

Keskar et al. (2017) identificam uma dicotomia fundamental na topologia dos mínimos locais encontrados por diferentes regimes de tamanho de lote:

- **Mínimos Planos (*Flat Minima*):** São regiões amplas e achatadas no espaço de parâmetros onde a função de custo tem valores baixos. Uma solução localizada em um mínimo plano é robusta, pois pequenas perturbações nos pesos (causadas pela diferença estatística entre dados de treino e teste) não resultam em um aumento significativo no erro. O treinamento com lotes pequenos (*Small-Batch*) tende a convergir para essas regiões devido ao ruído inerente na estimativa do gradiente, que atua como um mecanismo de exploração que evita "bacias" estreitas.
- **Mínimos Agudos (*Sharp Minima*):** São regiões estreitas onde a função de custo cresce abruptamente ao nos afastarmos do ponto ótimo. Embora possam apresentar erro de treino próximo a zero, essas soluções generalizam mal, pois um pequeno deslocamento no espaço de parâmetros (devido à mudança de domínio do teste) leva a uma degradação severa da performance. O treinamento com lotes grandes (*Large-Batch*) tende a ser atraído para esses mínimos, pois a estimativa precisa do gradiente reduz o ruído exploratório necessário para escapar deles..

2.2 Arquiteturas Convolucionais Profundas (VGG)

Para investigar fenômenos de otimização complexos, é necessário utilizar arquiteturas com capacidade suficiente para gerar superfícies de erro não-convexas e desafiadoras. Neste trabalho, baseamo-nos na arquitetura VGG (*Very Deep Convolutional Networks*), proposta por Simonyan e Zisserman (2014).

A VGG estabeleceu um paradigma importante ao demonstrar que a profundidade da rede é um componente crítico para o desempenho em reconhecimento de imagens. Sua característica marcante é o uso exclusivo de filtros de convolução muito pequenos 3x3, empilhados em sequência. Essa abordagem permite aumentar a não-linearidade da rede e a profundidade das representações aprendidas, mantendo o número de parâmetros sob controle comparado a filtros maiores. A complexidade da superfície de perda gerada por uma VGG torna-a um candidato ideal para validar a existência e o impacto dos mínimos agudos em regimes de *Large-Batch*.

2.3 Regularização e Dinâmica de Treinamento

O *overfitting* é um desafio constante em modelos profundos como a VGG. Uma das técnicas mais eficazes para combatê-lo é o *Dropout*, introduzido por Srivastava et al. (2014). O *Dropout* previne a co-adaptação complexa dos neurônios ao "desligar" aleatoriamente unidades (e suas conexões) durante o treinamento. Isso força a rede a aprender características mais robustas e distribuídas, funcionando como uma técnica de *bagging* implícita, onde o modelo final é a média de várias sub-redes "magras".

É importante notar o paralelo teórico entre o *Dropout* e o *Small-Batch Training*: ambos introduzem estocasticidade (ruído) no processo de aprendizado. Enquanto o *Dropout* adiciona ruído na arquitetura, o *Small-Batch* adiciona ruído na atualização dos gradientes. A hipótese central investigada neste trabalho sugere que, na ausência do ruído do *Small-Batch* (como ocorre no treinamento *Large-Batch*), a rede perde uma fonte vital de regularização implícita, levando à convergência para mínimos agudos, mesmo na presença de regularizadores explícitos como o *Dropout* ou *Weight Decay*.

3. Metodologia

Para investigar o fenômeno do *Generalization Gap* e a natureza dos mínimos locais, adotamos uma abordagem experimental dividida em duas etapas: a reprodução controlada dos experimentos de classificação de imagem e uma extensão aplicada à detecção de objetos.

3.1 Reprodução Experimental

Dataset e Arquitetura: Utilizamos o dataset CIFAR-10, composto por imagens naturais de complexidade suficiente para manifestar problemas de generalização, superando a trivialidade de datasets como MNIST. A arquitetura escolhida foi a rede SimpleVGG, uma adaptação simplificada das redes propostas por Simonyan & Zisserman (2014). O modelo consiste em três blocos convolucionais, cada um contendo camadas de Convolução, Batch Normalization e ReLU, seguidos de Max Pooling. O classificador final é composto por camadas lineares com regularização Dropout ($p=0.5$) para mitigar o overfitting.

Configuração de Treinamento: O modelo foi treinado em dois regimes distintos utilizando o otimizador SGD com Momentum (0.9), mantendo a semente aleatória fixa (seed 42) para garantir reprodutibilidade:

- **Regime Small-Batch (SB):** Tamanho de lote de 64, treinado por 40 épocas.
- **Regime Large-Batch (LB):** Tamanho de lote de 1024, treinado por 30 épocas. Para isolar o efeito geométrico do tamanho do lote, fixamos uma taxa de aprendizado conservadora ($\eta = 0.01$) em ambos os regimes, evitando técnicas de escalonamento linear ou warmup que poderiam mascarar a instabilidade inerente aos grandes lotes.

Análise da Geometria da Função de Custo: Para caracterizar os mínimos encontrados, implementamos duas métricas de avaliação baseadas em Keskar et al. (2017):

1. **Interpolação Linear 1D:** Traçamos a função de perda e a acurácia ao longo de uma linha que conecta os parâmetros finais do modelo SB (θ_{SB}) e do modelo LB (θ_{LB}), parametrizada por $\theta = (1 - \alpha) \theta_{SB} + \alpha \theta_{LB}$. Isso permite visualizar a "paisagem" da perda entre as duas soluções.
2. **Teste de Sensibilidade (*Sharpness Test*):** Quantificamos a agudeza dos mínimos adicionando ruído gaussiano aleatório ($\sigma = 0.01$) aos pesos dos modelos treinados e medindo a degradação percentual na acurácia de teste. Uma queda abrupta indica um mínimo agudo (frágil), enquanto uma queda suave indica um mínimo plano (robusto).

3.2 Extensão para Detecção de Objetos (YOLO)

Como extensão prática, avaliamos a robustez em uma tarefa de detecção de objetos utilizando a arquitetura YOLO (*You Only Look Once*). O modelo foi treinado em um dataset privado de monitoramento de tráfego contendo 11.174 imagens e 5 classes principais (Carro, Moto, Pessoa, Ônibus, Bicicleta). Comparamos dois regimes de treinamento:

- **Batch 16 (Small):** Representando o regime de alta estocasticidade.
- **Batch 128 (Large):** Representando o regime de maior rendimento (throughput). A avaliação de desempenho utilizou a métrica mAP (Mean Average Precision) e o teste de sensibilidade foi replicado neste contexto para verificar a queda de performance sob perturbação dos parâmetros.

Para quantificar o desempenho do modelo de detecção, adotou-se o **Mean Average Precision (mAP)**, a métrica padrão-ouro para tarefas de detecção de objetos. O mAP avalia a qualidade da detecção considerando tanto a classificação correta quanto a precisão da localização da caixa delimitadora (*bounding box*). O cálculo segue três etapas fundamentais:

- **Intersection over Union (IoU):** Mede a sobreposição entre a caixa predita e a caixa real (*ground truth*). Uma predição é considerada "correta" se o IoU superar um limiar τ (ex: 0.5).
- **Average Precision (AP):** Para cada classe, constrói-se uma curva de Precisão x *Recall*. O AP é a área sob esta curva, capturando o compromisso entre a capacidade do modelo de encontrar todos os objetos positivos e a precisão dessas detecções.
- **Mean Average Precision (mAP):** O mAP é a média dos valores de AP calculada sobre todas as classes do dataset.

Neste estudo, reportamos especificamente o **mAP@50-95** (padrão COCO), que calcula a média do mAP variando o limiar de IoU de 0.50 a 0.95 em passos de 0.05. Esta métrica é rigorosa, pois penaliza não apenas erros de classificação, mas também imprecisões geométricas leves nas caixas delimitadoras, sendo ideal para avaliar a robustez fina dos modelos treinados em diferentes regimes de lote.

4. Experimentos e Resultados

Nesta seção, apresentamos os resultados empíricos da investigação sobre o *Generalization Gap*. O estudo foi conduzido em duas frentes distintas: uma análise geométrica fundamental em um cenário de classificação (CIFAR-10 com arquitetura VGG) e uma validação prática em uma tarefa de detecção de objetos (YOLO em dataset de tráfego).

4.1 Resultados da Classificação

Inicialmente, avaliamos o comportamento de convergência e generalização ao variar o tamanho do lote (*batch size*). A **Figura 1** apresenta as curvas de aprendizado para regimes de *Small-Batch* (SB) e *Large-Batch* (LB).

Observa-se que, embora ambos os modelos atinjam uma acurácia de treino próxima a 100%, existe uma bifurcação significativa no desempenho de teste entre as redes neurais. O modelo LB apresenta uma estagnação precoce da acurácia de teste e, mais criticamente, um aumento progressivo na função de perda (*Test Loss*) após a época 10, indicando um *overfitting* severo. Em contraste, o modelo SB mantém uma perda de teste decrescente e estável, resultando em uma melhor generalização.




Figura 1 - Generalization Gap e Loss do Teste

Para investigar a geometria da solução encontrada, realizamos uma interpolação linear entre os parâmetros finais dos modelos, definida por $\theta(\alpha) = (1 - \alpha) \theta_{SB} + \alpha \theta_{LB}$. A Figura 2 ilustra a paisagem da função de custo e a variação da acurácia ao longo deste caminho:

- **Região de Small-Batch ($\alpha = 0$):** A curva de perda é notavelmente plana e a acurácia permanece estável nas vizinhanças de θ_{SB} . Isso caracteriza um "Mínimo Plano" (*Flat Minimum*), onde pequenas perturbações nos pesos não degradam o desempenho do modelo.
- **Região de Large-Batch ($\alpha = 1$):** A topologia revela um "Mínimo Agudo" (*Sharp Minimum*). Nota-se um crescimento abrupto da função de perda e uma queda vertiginosa da acurácia ao menor afastamento do ponto ótimo.




Figura 2 - Paisagem da Função de Custo e Variação da Acurácia

Para quantificar essa fragilidade geométrica, submetemos ambos os modelos a testes de sensibilidade com adição de ruído. A Figura 3 corrobora a hipótese geométrica: sob o mesmo ruído, o modelo LB sofre uma degradação catastrófica de **30,0%** em sua acurácia, enquanto o modelo SB demonstra robustez, com uma queda marginal de apenas **3,1%**.




Figura 3 - Evidência de Sharpness

4.2 Validação em Detecção de Objetos

A segunda etapa do experimento estendeu a análise para a arquitetura YOLO, um modelo de alta complexidade para detecção de objetos. A **Figura 4** compara o desempenho em termos de *Mean Average Precision* (mAP50-95). O modelo treinado com lotes pequenos (16) superou consistentemente o modelo de lotes grandes (128), tanto no conjunto de treino quanto no de validação (0.603 vs 0.590 no mAP de validação). Este resultado confirma que a degradação de generalização observada em classificação se traduz diretamente para tarefas de regressão e localização.

A análise de sensibilidade para a detecção é apresentada na **Figura 5**. Embora a escala de degradação seja menor em comparação à classificação pura, mantém-se a tendência de maior vulnerabilidade no regime de grandes lotes. A consistência desses resultados sugere que a "agudeza" dos mínimos locais prejudica a capacidade do modelo de aprender características invariantes necessárias para a detecção robusta de objetos.




Figura 4 - Acurácia mAP de SB vs LB




Figura 5 - Evidência de Sharpness no mAP

5. Discussão e Análise Crítica

A convergência dos resultados entre as arquiteturas VGG e YOLO permite uma análise crítica sobre a natureza do aprendizado profundo. A evidência geométrica sugere que o Gradiente Descendente Estocástico (SGD) com pequenos lotes não é apenas um método de otimização, mas um mecanismo de regularização implícita.

O ruído introduzido pelo *Small-Batch* atua como uma “força que move” o otimizador para fora de vales estreitos e irregulares. Em modelos complexos como a YOLO, onde a função de custo envolve tanto termos de classificação quanto de regressão de coordenadas (Bounding Boxes), essa exploração é vital. No regime *Large-Batch*, a estimativa do gradiente é excessivamente precisa, o que prejudica o modelo ao permitir que ele se "encaixe" perfeitamente em irregularidades do conjunto de treino que não representam a distribuição real dos dados.

A fragilidade demonstrada nos testes de *sharpness* (sensibilidade ao ruído) possui implicações práticas significativas. Modelos de detecção de objetos em veículos autônomos ou sistemas de segurança precisam ser robustos a variações. Se uma rede reside em um mínimo agudo, ela se torna hipersensível a ruídos de sensores ou mudanças de iluminação, podendo falhar em situações críticas onde um modelo treinado com maior estocasticidade (Small-Batch) permaneceria estável.

6. Conclusão e Trabalhos Futuros

Este estudo validou a correlação entre o tamanho do lote e a geometria dos mínimos locais em redes neurais profundas. Demonstramos que, embora o treinamento com grandes lotes ofereça eficiência computacional, ele sacrifica a robustez geométrica e a capacidade de generalização.

Para pesquisas subsequentes, propomos duas frentes de investigação que visam mitigar esses problemas ou aprofundar a compreensão da dinâmica de otimização:

1. **Otimizadores Adaptativos vs. Geometria:** Investigar se otimizadores modernos baseados em momentos adaptativos, como o **Adam**, sofrem do mesmo problema geométrico de convergência para mínimos agudos observado no SGD puro em regimes de *Large-Batch*. O objetivo é entender se a adaptação da taxa de aprendizado por parâmetro consegue compensar a perda de estocasticidade.
2. **Implementação de Ghost BatchNorm:** Avaliar o impacto da técnica de **Ghost Batch Normalization** em treinamentos de larga escala. Esta técnica visa simular as estatísticas de normalização de lotes pequenos (mais ruidosas e regularizadoras) dentro de um lote grande, buscando "enganar" a rede para que ela mantenha a estabilidade de vales planas sem sacrificar o *throughput* de hardware.