


# On Large-Batch Training for Deep Learning

Investigando o Generalization Gap e a Geometria dos Mínimos Locais



## Uma análise aprofundada do artigo de Keskar et al. (ICLR, 2017)

O Mistério: Por que o treinamento com grandes lotes (Large-Batch), essencial para o paralelismo em supercomputadores, resulta em modelos que falham no mundo real, mesmo apresentando acurácia de treino perfeita?

*Projeto Final - Tópicos Avançados  
em Aprendizado de Máquina*

# Referências e Equipe

## Equipe de Projeto

Gabriel Batista Monteiro - 542561

Luan Icaro Ferreira Santos - 415170

## Referência Principal

Keskar et al., On Large-Batch Training for Deep Learning: Generalization Gap and Sharp Minima, ICLR 2017.


## Leitura Complementar

- Simonyan & Zisserman (VGG)
- Kingma & Ba (Adam)
- Srivastava et al. (Dropout)



# O Dilema da Otimização: Eficiência vs. Qualidade

## O Incentivo (Hardware)



**A Promessa do Hardware:** **GPUs** e **TPUs** modernas favorecem o processamento massivo paralelo.


**Large-Batch (LB):** Processar **1.000+ imagens** simultaneamente permite treinos muito mais rápidos. Matematicamente, o gradiente é **mais preciso**

## A Armadilha (Generalização)

**O Fenômeno do Generalization Gap:** Modelos LB atingem **alta acurácia** nos dados de treino, mas **generalizam mal** para **dados novos** (teste).



**Small-Batch:** Estudar aos poucos




**Large-Batch:** Decorar tudo de uma vez

**Analogia Didática:** Quem **estuda aos poucos absorve conceitos**. Quem **decora tudo** na véspera passa na prova (treino), mas **esquece tudo depois** (teste)

# A Hipótese Geométrica: Vales Planos vs. Buracos de Golfe


## Small-Batch (SB): Mínimos Planos (Flat Minima)

- O "**Bêbado**": O ruído na estimativa do gradiente faz a otimização "tropeçar" e escapar de buracos estreitos.
- **Benefício**: Vales largos são robustos. Pequenas mudanças nos dados não afetam o erro.




## Large-Batch (LB): Mínimos Agudos (Sharp Minima)

- O "**Laser**": O gradiente preciso segue uma linha reta para o mínimo mais próximo.
- **Problema**: Semelhante a um "buraco de golfe". Um milímetro de deslocamento faz o erro explodir.




# Metodologia Experimental: Recriando a Cena

Para validar a hipótese, reproduzimos os experimentos em um ambiente controlado usando PyTorch




O Dataset

**CIFAR-10:** Escolhido pela complexidade das imagens naturais. O MNIST seria trivial demais para manifestar problemas de generalização



A Arquitetura

**SimpleVGG:** Rede Convolutiva baseada em Simonyan & Zisserman  
**Componentes:** 3 Blocos Convolucionais, Batch Normalization, ReLU, Max Pooling e Dropout




Os Regimes

**Small-Batch (SB):** Tamanho 64  
(Alto ruído estocástico)

**Large-Batch (LB):** Tamanho 1024  
(Baixo ruído estocástico)

# Detalhes de Implementação e Ajustes Críticos



**Contexto:** O treinamento com Large-Batch é instável e tende a divergir se não for tratado corretamente.



## Configuração Final

- Otimizador: SGD com Momentum (0.9)
- Épocas: 40 (SB) vs 30 (LB) - LB converge mais rápido em wall-clock time, mas requer cuidado
- Hardware: GPU NVIDIA (Ambiente Colab)


# Evidência A: A Ilusão do Sucesso no Treino



## Análise das Curvas:

- **Linhas Tracejadas (Treino):** Observe que ambos os modelos (Azul/SB e Vermelho/LB) atingem alta acurácia de treino. O LB aprendeu os dados
- **Linhas Sólidas (Teste):** Aqui reside o problema. O modelo Small-Batch (Azul) supera consistentemente o Large-Batch (Vermelho)
- **O Veredito:** Existe um gap de performance (~9%) que não é explicado por falta de convergência, mas pela qualidade da solução encontrada

# Investigando a Topologia: Como 'ver' a Geometria?




$$\theta(\alpha) = (1 - \alpha)\theta_{SB} + \alpha\theta_{LB}$$


Traçamos uma linha reta matemática conectando os pesos finais dos dois modelos.

**Expectativa:** Se a teoria estiver correta, ao redor de  $\alpha = 0$  (SB), a curva de erro deve ser suave e larga. Ao redor de  $\alpha = 1$  (LB), a curva deve ser íngreme e estreita

# Evidência B: A Topologia do Fracasso



**Small Batch (Azul):** A curva é plana. Mover-se para a esquerda ou direita altera pouco a Loss. Isso é um **Mínimo Plano**



**Large Batch (Vermelho):** A curva é um pico estreito. Qualquer movimento para fora de  $a=1$  causa uma explosão imediata na Loss. Isso é um **Mínimo Agudo**

# O Teste de Estresse: A Prova do "Terremoto"

**Conceito:** Se a geometria visualizada for real, os modelos devem reagir de forma diferente a perturbações aleatórias

## Metodologia (Sensitivity Metric):

1. Tomar os modelos treinados.
2. Adicionar ruído aleatório aos pesos (simulando um "terremoto" ou a variabilidade natural de dados de teste).
3. Medir a queda na acurácia.




Modelo "Borracha" (SB): Deve absorver o impacto



Modelo "Vidro" (LB): Deve quebrar sob tensão

# Evidência C: Quantificando a Fragilidade (Sharpness)



**Small Batch (Azul):** Queda de apenas 3.1%. O modelo permanece funcional. (Robusto)

**Large Batch (Vermelho):** Queda catastrófica de 30.0%. O modelo colapsa. (Frágil)

O modelo LB não apenas generaliza pior, ele é fundamentalmente mais frágil a perturbações nos parâmetros.

# Análise Crítica e Limitações


## Pontos Fortes

- A explicação geométrica é elegante e os resultados são reprodutíveis.
- Confirma que "ruído" no treinamento é uma feature, não um bug

## Limitações Observadas

- **Necessidade de Tuning:** Sem Warmup e ajuste fino de LR, o Large-Batch sequer converge (divergência observada nos testes iniciais).
- **Updates vs. Épocas:** O SB realiza muito mais atualizações de pesos por época ( $N/64$ ) que o LB ( $N/1024$ ). Isso confere uma vantagem computacional implícita ao SB.
- **Batch Normalization:** O comportamento estatístico do BN muda com o tamanho físico do batch, o que pode influencia

# Cenário Real




**Deteção de Objetos:**  
Testar a hipótese com  
YOLO em dataset de  
monitoramento de  
tráfego. A fragilidade se  
mantém na métrica mAP?

# YOLO (You Only Look Once)

A rede neural YOLO(You only look once) é capaz de fazer **Detecção de Objetos** através de técnicas de visão computacional.

## Configuração Final

- Otimizador: SGD com Momentum (0.937)
- Épocas: 40 (**SB**) vs 40 (**LB**)
- Hardware: GPU NVIDIA
- Batches de 16 e 128 imagens



# YOLO (You Only Look Once)

Predição YOLO




# Dataset

## **Dataset: 11174 imagens**


- 7821 imagens de treino
- 3353 imagens de validação

As classes são:


- Pessoa (5695 instâncias)
- Bicicleta (1165 instâncias)
- Carro (44691 instâncias)
- Moto (11861 instâncias)
- Ônibus (1946 instâncias)
- Van (304 instâncias)
- Caminhão (868 instâncias)




# O que é a métrica mAP?




$$IoU = \frac{\text{area of overlap}}{\text{area of union}}$$



# O que é a métrica mAP?




$$IoU = \frac{\text{area of overlap}}{\text{area of union}}$$




# Resultados

## O modelo


- Duas versões: uma com batch de 16 imagens e outra de 128 imagens
- Em dados reais, a YOLO com batch menor tem maior acurácia
- Treinado em um dataset privado de trânsito para detectar veículos



# Resultados




# Resultados



# Extensões Futuras


## Otimização



### Otimizadores Modernos:

Comparar se o Adam (adaptativo) sofre do mesmo problema geométrico que o SGD puro

## Normalização



### Ghost BatchNorm:

Implementar técnicas que simulam estatísticas de batches pequenos mesmo durante treinos com batches grandes

# Conclusão: A Pressa é Inimiga da Perfeição

- Nossa reprodução confirmou que o tamanho do batch dita a geometria da solução final.
- **Large-Batch (Vermelho):** Eficiente computacionalmente, mas tende decorar dados em soluções agudas e frigeis
- **Small-Batch (Azul):** O ruído estocástico atua como um regularizador essencial, guiando a rede para vales largos e robustos.

Para aplicações críticas onde a generalização é chave, a eficiência do treinamento não pode vir às custas da geometria da função de perda.

**Obrigado!**